

AI koji generiše sliku na osnovu teksta

Budimir Nikola 178/2021
Trajković Miljan 354/2022
Cvejić Miloš 346/2021
Bajić Bogdan 122/2021

17. novembar 2022.

Ovo je test!

Sažetak

Sadržaj

1	Kako funkcionišu AI generatori slika	2
1.1	Pregled arhitekture DALL-E 2 softvera	3
2	Treniranje AI generatora slika	5
3	Etički problemi sa veštačko inteligentnim generatorima slika	6
3.1	Problem autorskih prava	6

1 Kako funkcionišu AI generatori slika

Preteče današnjih generatora

Mnogi modeli vestacke inteligencije pa tako i generatori slika na osnovu teksta poput **DALL-E 2** i drugih, zasnovani su na prethodnim istraživanjima i prethodnim modelima iz ove oblasti. Generisanje slika razvijalo se linearno i to prvobitno koriscenjem mreža koje koriste metode suparničkog učenja odnosno “Generative adversarial network” (GANs).

GANs su modeli mašinskog učenja obično sačinjeni od dve mreže, *diskriminatora* i *generatora*, koje međusobnim intereagovanjem treniraju jedna drugu. Naime, ako uzmemo na primer generisanje slika, zadatak diskriminatora je da što sigurnije i preciznije odredi da li je njemu zadata slika, prava fotografija iz neke baze podataka ili je to generisana slika. Na drugoj strani, zadatak generatora je da prevazi diskriminatora, odnosno da što bolje nauči šta sliku čini “pravom” i tako napravi sliku za koju se ne može utvrditi da li je ona prava ili ne. U tom slučaju interakcija ove dve mreže i njihovo treniranje se može posmatrati kao minimax igra u kojoj se diskriminator trenira da maksimalno uveća verovatnoću tačnog određivanja klase slika, dok se generator trenira da maksimalno umanji verovatnoću da slike koje je generisao budu klasifikovane od strane diskriminatora kao generisane slike.[1, 2, 3]

Ključna razlika između ovako opisanih mreža i najnovijih AI generatora slika je ta što se klasični GAN modeli obično razvijaju za neku konkretnu kategoriju fotografija(npr. popularni generator ljudskih lica)[4] dok na drugoj strani generatori poput DALL-E 2, Stable Diffusion, Imagen-a su mnogo opštije namene i možemo im zadati tekstualni opis slike koju očekujemo od generatora. To zadavanje opisa se realizuje proširivanjem već pomenutih mreža tako što se generatoru prosleđuje uslov po kom će on generisati sliku.[5, 6, 8] Formiranje ovog uslova je zapravo netrivialna stvar jer najbolje realizacije generatora nisu one u kojima se kao uslov prosleđuje samo opis slike što je i pokazano u istraživanju openai tima.[5]

Arhitekture najnovijih generatora zasnovane su na jednoj od novijih tehnika nazvanoj difuzija(eng. diffusion) koja je inspirisana oblašću iz fizike - neravnotežna termodinamika. Naime ako sipamo kap farbe u vodu, zakoni fizike govore da ta kap *difunduje*¹ sve dok ne dođe u ravnotežu. Ovaj proces u prirodi je ireverzibilan. U mašinskom učenju, modeli difuzije nastoje da reše

¹Difundovanje - proces spontanog raspršivanja materije i energije, prelazak iz zone više u zonu niže energije ili koncentracije

upravo ovaj problem, odnosno da nađu način kojim mogu doći do početne kapi farbe.[8]

1.1 Pregled arhitekture DALL-E 2 softvera

Na primeru konkretnog generatora DALL-E 2 možemo videti prethodno opisane mreže i koju ulogu one imaju u jednom od najpoznatijih softvera za generisanje slika.

Za pocetak posmatracemo takozvanu CLIP mrežu (skraceno od Contrastive Language–Image Pre-training), koja je izuzetno bitna za treniranje osnovnih komponenti ovog generatora. Njen osnovni zadatak je da zadatu sliku poveže sa odgovarajućim zadatim opisom. Primetimo da se na neki način generisanje slika može smatrati suprotnim procesom od pomenutog, a razlog zašto je ova mreža od ključnog značaja prilikom generisanja ćemo videti u nastavku teksta. Na ulazu CLIP mreže nalaze se dva kodera koji kodiraju zadatu sliku i njen opis u odgovarajući *imbeding*², zasebice. Prilikom treniranja, CLIP nastoji da pomenute kodere nauči da imbeding slike i imbeding njenog opisa budu što sličniji jedan drugom.[7, 5]

Sama arhitektura Dall-e 2 softvera se sastoji iz dva dela. Prvi deo čini mreža prior³ koji na ulazu prima tekst imbeding (formiran CLIP kodiranjem tekstualnog opisa željene slike) koji preslikava u imbeding slike koji prosleđuje drugom delu ovog generatora - dekoderu. Sada dolazimo do ključnog značaja CLIP mreže. Openai tim se zapitao, da li je prior u ovom pristupu uopšte potreban. Iz tog razloga pokušali su da dekoderu proslede samo tekstualni opis, zatim tekstualni opis i tekst imbeding, a na kraju i imbeding slike dobijen pomoću prior-a. Iz tog eksperimenta su zaključili da slike generisane imbedingom slike daju značajno bolje rezultate u odnosu na druga dva slučaja.[5]

Dekoder je generativni model realizovan pomenutom tehnikom difuzuje. Naime, slike se generišu iz nasumične količine *Gausovog šuma*⁴. Zadatak generatornog dela je da pretpostavi koliko šuma je na slici i otkloni ga. Ovo je vrlo težak problem koji se uspešno rešava upravo difuzno i to na sledeći način. Otklanjanje šuma vrši se iterativno[4]. U svakoj iteraciji pretpostavlja

²imbeding (engl. embedding) - rezultat preslikavanja skupa informacija u računarski zapis, vektor

³prior - označava ono što je pre nečega po redu ili hronološki.

⁴Gausov šum (engl. Gaussian noise) - šum raspoređen korišćenjem Gausove normalne raspodele

se koliko šuma je na slici koji se otklanja, a zatim se na dobijenu sliku dodaje skoro malo manja količina gausovog šuma od prethodnog i prelazi u sledeću iteraciju. Kako bi dekodер znao šta uopšte treba da generiše, odnosno “šta se nalazi ispod šuma” prosleđuje mu se uslov. Kod ranijih projekata kao što su GLIDE i DALL-E[6, 5], dekodерu se kao uslov direktno prosleđivao tekstualni opis željene slike. Dok se kod ovog modela zahvaljujući CLIP i prior mreži generatoru dodatno prosleđuju CLIP imbeding slike i teksta. Generisanje različitih slika i variranje u odnosu na jednu generisanu sliku se postiže tako što se dobijena slika propušta kroz CLIP koder kako bi se dobio njen imbeding slike, a onda se proces generisanja ponavlja sa novodobijenim imbedingom. Na ovaj način dobija se slika koja ima iste elemente i stil prethodne slike, a različit raspored i neke trivijalne detalje koji se gube CLIP kodiranjem. Izlaz opisanog dela dekodera je slika formata 64x64.

Zato se na samom kraju ovog generatora slika rezolucije 64x64 prolazi kroz još dva ekspanzivna koraka kojim se slika dovodi na rezoluciju 1024x1024. Ovi koraci su takođe realizovani difuznim tehnikama što doprinosi tome da slika na izlazu ima više detalja i bude maksimalno fotorealistična.[5]

2 Treniranje AI generatora slika

Kako smo već objasnili neke od modela mašinskog učenja koji se koriste u generatorima slika može samo dodati neke ključne detalje koji su bitni kod ovako velikih projekata.

Trening softvera kao što generator slika obično zahteva ogromne baze podataka slika koje su pažljivo birane za ovaj trening. Naravno, kreiranje ovakvih baza podataka i prikupljanje slika generalno zahteva veliki broj ljudi koji rade na ovom projektu. Jedna od najzahtevnijih baza jeste The ImageNet baza slika na kojoj je radilo preko 25 hiljada ljudi koji su skupili 14 miliona slika na kojima se može naći 22 hiljade različitih objekata. Interesantno je to da OpenAi tim nije utrošio ovakve napore prilikom treniranja Dall-e 2 generatora. [7]

Već smo pričali o CLIP mreži. Tokom njenog treniranja ona prima parove slika i njihovih opisa. Parove slika i njihovih opisa pronalazi na internetu. Možemo primetiti da slike dobijene gubl pretragom, kao i slike na društvenim mrežama poput instagrama i tvitera gotovo uvek imaju opise i lako im je pristupiti. Samim tim trošak na građenje iscrpnih baza slika potpuno je prevaziđen. [7, 5]

Treniranje dekodera svodi se na treniranje difuznog modela. Najbitnije je pomenuti jednu difuznu tehniku zvanu navođenje bez klasifikatora (eng. Classifier-free guidance). Ova tehnika podrazumeva da se generatoru u određenom broju slučajeva prosleđeni CLIP imbeding postavljaju na nulu, čime je generator forsiran da napravi sliku samo na osnovu teksta. A tokom treniranja 50% posto generacija izvršava se bez teksta, odnosno samo pomoću CLIP imbedinga.

Takođe, tokom treniranja mreža koje sliku rezolucije 64x64 proširuju na sliku rezolucije 1024x1024, slike koje dolaze na ulaz mogu biti malo zamućene korišćenjem Gausove normalne raspodele. Kao što smo rekli baš zbog ovih difuznih tehnika na izlazu dekodera dobijamo sliku rezolucije 1024x1024 koja je fotorealistična i može sadržati puno detalja. [5]

3 Etički problemi sa veštačko inteligentnim generatorima slika

AI generatori slika mogu doprineti diskriminaciji tako što oponašaju štetne stereotipe koje je AI prikupio u kolekcijama podataka, koji sami imaju predrasude iz svakodnevnog života.

U svom članku Rune Klingenberg Hansen nudi sledeća rešenja [10]. Problem se može korigovati zabranjivanjem određenih reči ili nasumičnim dodavanjem prefiksa kao što su: žena/muškarac/trans, crna/žuta/braon osoba, kvir⁵ itd.). Ali nekada automatsko dodavanje dodatnih reči može negativno uticati umesto da reši problem. Npr. dodavanje reči žena za neke termine koji se koriste za osobe svih polova ili dodavanje reči crnac kada se spominju bande/karteke.

Još jedan problem je mogućnost veštačke inteligencije da generiše lažne informacije. To je upravo razlog zašto DALL-E [11] ne dozvoljava generisanje slika sa poznatim osobama [12], ali lažne informacije ne utiču samo na poznate ljude. Npr. ljudi se mogu svetiti svojim bivšim partnerima ili članovima svoje porodice.

Ali možda najstrašnije stvar jeste da ova tehnologija može u potpunosti uništiti naše poverenje u slike kao verodostojan dokaz. Zbog straha da su slike lažne, jer generator slika nam omogućava da kreiramo fotorealistične slike. Opasnost od ovog scenarija se može umanjiti korišćenjem tehnologija koje imaju sposobnost detektovanja lažnih slika. Takođe mogli bismo zahtevati da veštački generisane slike imaju neku oznaku, pogotovo kada su u pitanju fotorealistične slike.

3.1 Problem autorskih prava

Svi mi svakodnevno koristimo slike za razmenjivanje ideja i vizuelna reprezentacija sadržaja je sada više nego ikada dostupna svima nama. Pored lične upotrebe, slike su u savremenom kapitalističkom društvu postale sredstvo promovisanja usluga i proizvoda (naslovnice knjiga, bilbordi itd.). Generatori slika svima nama dozvoljavaju da kreiramo potpuno nove slike i da ih koristimo u komercijalne svrhe, ali onda se javlja pitanje ko polaže autor-

⁵kvir (engl. queer) - naziv za celokupnu homoseksualnu, biseksualnu, transrodnu i interseksualnu zajednicu kao i heteroseksualne osobe koje sebe vide ili žive svoj život van heteropatrijarhalnih normi.

ska prava nad tim generisanim slikama. Da li osoba koja je okucala tekst i pritisnula dugme za generisanje, da nije algoritam koji je izgenerisao sliku ili pak kompanija koja je kreirala algoritam?

Takođe, generatori slike imaju mogućnost da oponašaju umetnički stil mnogih poznatih umetnika. S jednim klikom korisnik može da izgeneriše hiljade slika u stilu Leonarda Da Vinčija. Da li je u tom slušaju korisnik plagirao životno delo slikara? Generator slika ne samo da uzima inspiraciju iz jedne slike umetnika, već kreira slike na osnovu njegovog celokupnog životnog dela.

Na prvu loptu ovo nam zvuči kao očigledan plagijat, ali moramo sagledati širu sliku. Kao što ljudskog biće dobija inspiraciju iz svega što ga okružuje, tako i veštačka inteligencija dobija inspiraciju iz kolekcija podataka koje analizira. U apstraktnom smislu, način na koji čovek i veštačka inteligencija kreiraju slike je dosta sličan. Oboje imaju neku početnu ideju koja proizašla iz informacija koje su dobili na njima prirodan način. Čovek ih dobija preko svojih čula, dok veštačka inteligencija ih, trenutno, dobija u binarnom zapisu na nekom medijumu za skladištenje podataka. Polazeći iz ideje, oboje biraju korake koji ih vode prema tome da završnim proizvod bude njihova lična kreacija. Jedina razlika između čoveka i veštačke inteligencije je činjenica da je veštačka inteligencija mnogo brža i efikasnija u tom procesu. Može se reći da je veštačka inteligencija umnogome sposobnija od čoveka.

Ukoliko bismo živeli u svetu gde je čovek podjednako inteligentan kao veštačka inteligencija ne bi nam bilo ni čudno ni pogrešno da čovek može da kreira s tolikom preciznošću i brzinom. To što je veštačka inteligencija trenutno samo jedno polje na veb stranici ne treba da nas zavara da će veštačka inteligencija jednog dana, vrlo verovatno, sama stvarati i evoluirati.

Generatori slika stvarno kreiraju problem celokupnoj kreativnoj industriji, ali treba na veštačku inteligenciju posmatrati kao na još jednu alatku koju umetnik može da koristi. Možda upravo uz pomoć veštačke inteligencija umetnost može postati brža, dostupnija i otvorenija [13].

Literatura

- [1] Stanislav Frolov, Tobias Hinz, Federico Raue, Jörn Hees, Andreas Dengel, Adversarial text-to-image synthesis: A review. Dostupno na adresi <https://www.sciencedirect.com/science/article/pii/S0893608021002823>
- [2] Scott Reed, Zeynep Akata, Xincheng Yan, Lajanugen Logeswaran, Bernt Schiele, Honglak Lee, Generative Adversarial Text to Image Synthesis. Dostupno na adresi <http://proceedings.mlr.press/v48/reed16.pdf/>
- [3] Computerphile, Generative Adversarial Networks (GANs) - Computerphile. Dostupno na adresi <https://www.youtube.com/watch?v=Sw9r8CL98N0/>
- [4] Computerphile, How AI Image Generators Work (Stable Diffusion / Dall-E) - Computerphile. Dostupno na adresi <https://www.youtube.com/watch?v=1CIpzeNxIhU/>
- [5] Aditya Ramesh, Prafulla Dhariwal, Alex Nichol, Casey Chu, Mark Chen, Hierarchical Text-Conditional Image Generation with CLIP Latents. Dostupno na adresi <https://cdn.openai.com/papers/dall-e-2.pdf/>
- [6] Alex Nichol, Prafulla Dhariwal, Aditya Ramesh, Pranav Shyam, Pamela Mishkin, Bob McGrew, Ilya Sutskever, Mark Chen, GLIDE: Towards Photorealistic Image Generation and Editing with Text-Guided Diffusion Models. Dostupno na adresi <https://arxiv.org/abs/2112.10741/>
- [7] OpenAI, CLIP: Connecting Text and Images. Dostupno na adresi <https://openai.com/blog/clip/>
- [8] AssemblyAI, How does DALL-E 2 actually work? Dostupno na adresi <https://www.youtube.com/watch?v=F1X4fHzF4mQ&t=359s/>
- [9] AssemblyAI, Diffusion models explained in 4-difficulty levels. Dostupno na adresi <https://www.youtube.com/watch?v=yTAMrHVG1ew&t=53s/>

- [10] Rune Klingenberg Hansen, AI Image Generator: This Is Someone Thinking About Data Ethics. Dostupno na adresi <https://dataethics.eu/ai-image-generator-this-is-someone-thinking-about-data-ethics/>
- [11] DALL-E 2. Dodatne informacije dostupne na adresi <https://openai.com/dall-e-2/>
- [12] DALL-E 2 Content policy. Dostupno na adresi <https://labs.openai.com/policies/content-policy>
- [13] Paul Ford, Dear Artists: Do Not Fear AI Image Generators. Dostupno na adresi <https://www.wired.com/story/artists-do-not-fear-ai-image-generators/>